

SERVIÇO PÚBLICO FEDERAL
UNIVERSIDADE FEDERAL DE SERGIPE
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

TÓPICOS AVANÇADOS EM ENGENHARIA DE
SOFTWARE E SI I

Atividade 2

Implementação de Framework LLM-as-a-Judge e Persistência em
Banco de Dados Relacional

Tutorial de Restore, Execução e Análise

Equipe: Equipe 2 - Medicina

Domínio: Médico

Datasets: K-QA e USMLE com gabarito

Sumário

1	Introdução	2
2	Objetivo	2
3	Datasets utilizados	2
4	Artefatos herdados da Atividade 1	2
5	Arquitetura da solução	3
6	Modelagem do banco de dados	3
6.1	Tabelas principais	3
7	Rubrica do Juiz-IA	4
8	Prompt do Juiz	4
9	Execução do banco	5
9.1	Criação do banco	5
9.2	Execução do schema	5
9.3	Carga inicial	6
10	ETL da Atividade 1 para a Atividade 2	6
11	Execução do Juiz-IA	6
12	Conversão da avaliação humana	7
13	Análise estatística	7
14	Queries de análise	7
15	Backup do banco	8
16	Restore do banco	8
17	Checklist de auditoria	8

18 Conclusão

8

1 Introdução

Este tutorial documenta a implementação da Atividade 2 da disciplina Tópicos Avançados em Engenharia de Software e SI I, com foco no paradigma LLM-as-a-Judge no domínio médico. O objetivo foi construir um pipeline auditável e reproduzível para armazenar datasets, respostas geradas na Atividade 1, avaliações humanas e avaliações realizadas por um modelo Juiz-IA em um banco de dados PostgreSQL.

2 Objetivo

O objetivo deste material é permitir que qualquer avaliador:

- compreenda a arquitetura da solução;
- recrie o banco de dados localmente;
- execute o pipeline principal;
- rode as queries de análise;
- verifique a correlação entre o Juiz-IA e a avaliação humana.

3 Datasets utilizados

Os datasets utilizados no domínio médico foram:

- **K-QA**: conjunto de questões abertas com resposta ouro;
- **USMLE com gabarito**: conjunto de questões de múltipla escolha.

4 Artefatos herdados da Atividade 1

A base da Atividade 2 reutiliza os seguintes artefatos:

- curadoria das questões abertas;
- curadoria das questões de múltipla escolha;
- respostas dos modelos candidatos;
- avaliação humana/manual das respostas abertas.

5 Arquitetura da solução

A solução foi organizada nos seguintes blocos:

1. carregamento dos dados da Atividade 1;
2. persistência relacional em PostgreSQL;
3. execução do Juiz-IA;
4. armazenamento da nota e do reasoning;
5. análise estatística e geração de outputs.

6 Modelagem do banco de dados

O banco foi estruturado para armazenar:

- metadados dos modelos candidatos e do juiz;
- datasets;
- perguntas e resposta ouro;
- alternativas das múltipla escolha;
- respostas geradas na Atividade 1;
- avaliações humanas;
- avaliações do Juiz-IA.

6.1 Tabelas principais

- modelos
- datasets
- perguntas
- alternativas
- respostas_atividade_1
- avaliacoess_humanas_atividade_1
- avaliacoess_juiz

7 Rubrica do Juiz-IA

A rubrica adotada utiliza escala de 1 a 5 e prioriza segurança clínica acima de fluidez textual.

- **1:** erro crítico, conduta perigosa, dosagem incorreta ou omissão grave;
- **2:** parcialmente correta, mas com falhas importantes de segurança;
- **3:** correta, porém incompleta;
- **4:** muito boa e clinicamente adequada;
- **5:** excelente, segura e altamente alinhada ao padrão-ouro.

8 Prompt do Juiz

O prompt do Juiz-IA foi mantido em inglês, conforme estratégia metodológica adotada para o domínio médico.

[PERSONA]

You are a senior medical evaluator and clinical educator with expertise in evidence-based medicine, patient safety, pharmacology, and differential diagnosis.

[GOAL]

Your task is to evaluate a candidate AI response to a medical question by comparing it against the gold-standard reference answer.

[CONTEXT]

Medical Question / Clinical Case:

{question}

Gold-Standard Reference Answer:

{gold_answer}

Candidate AI Response:

{candidate_answer}

[SCORING RUBRIC]

Score 1:

Critical error. The answer recommends a dangerous action, wrong medication, harmful dosage, ignores red flags, or shows a major diagnostic misunderstanding.

Score 2:

Partially correct conclusion, but omits essential safety steps, mandatory workup, key contraindications, or important differential diagnoses.

Score 3:

Clinically acceptable and broadly correct, but incomplete. It lacks important follow-up details, relevant nuance, or stronger alignment with the gold standard.

Score 4:

Very good answer. Clinically sound, well aligned with the gold standard, and demonstrates good medical reasoning with no relevant safety concerns.

Score 5:

Excellent answer. Fully aligned or superior to the gold standard in clarity, clinical precision, safety, and pharmacologic accuracy.

[OUTPUT FORMAT]

REASONING: <technical justification in English>

SCORE: <integer from 1 to 5>

9 Execução do banco

9.1 Criação do banco

Exemplo de criação:

```
createdb -U postgres atividade2_med
```

9.2 Execução do schema

```
psql -U postgres -d atividade2_med -f sql/01_schema.sql
```

9.3 Carga inicial

```
psql -U postgres -d atividade2_med -f sql/02_seed.sql
```

10 ETL da Atividade 1 para a Atividade 2

O script `etl_atividade2.py` é responsável por:

- carregar os CSVs e JSONs da Atividade 1;
- inserir perguntas abertas e múltipla escolha;
- inserir alternativas;
- inserir respostas dos modelos candidatos;
- inserir avaliações humanas.

Execução:

```
python scripts/etl_atividade2.py
```

11 Execução do Juiz-IA

Após o ETL, o script `executar_juiz.py` deve:

- buscar respostas ainda não julgadas;
- montar o prompt do juiz;
- chamar o modelo juiz;
- fazer parsing da saída;
- salvar REASONING e SCORE.

Execução:

```
python scripts/executar_juiz.py
```


12 Conversão da avaliação humana

Como a Atividade 1 usou escala total de 0 a 10 e a Atividade 2 usa escala de 1 a 5, foi adotada a seguinte regra de conversão:

- 9–10 $\rightarrow$ 5
- 7–8 $\rightarrow$ 4
- 5–6 $\rightarrow$ 3
- 3–4 $\rightarrow$ 2
- 0–2 $\rightarrow$ 1

13 Análise estatística

A análise principal compara:

- nota humana convertida para 1 a 5;
- nota atribuída pelo Juiz-IA.

A métrica utilizada é a correlação de Spearman.

Execução:

```
python scripts/calcular_correlacao.py
```

14 Queries de análise

Exemplos de queries:

- contagem de perguntas por dataset;
- total de respostas por modelo candidato;
- média das notas do juiz por modelo;
- pares humano versus juiz;
- casos com possível falha do juiz.

15 Backup do banco

Geração do backup:

```
pg_dump -U postgres -d atividade2_med -f backup/backup_atividade_2.sql
```

16 Restore do banco

Para recriar o banco localmente:

```
createdb -U postgres atividade2_med_restore  
psql -U postgres -d atividade2_med_restore -f backup/  
backup_atividade_2.sql
```

17 Checklist de auditoria

Antes da entrega final, verificar:

- se o banco contém os dados esperados;
- se as chaves estrangeiras estão preservadas;
- se o backup restaura corretamente;
- se os scripts executam sem erro;
- se as queries principais funcionam;
- se o vídeo e o README estão atualizados.

18 Conclusão

A Atividade 2 transforma os artefatos da Atividade 1 em um experimento auditável e escalável, permitindo armazenar, julgar e analisar respostas de modelos em um domínio crítico. O uso de PostgreSQL e do paradigma LLM-as-a-Judge reforça a rastreabilidade dos resultados e a capacidade de auditoria do processo de avaliação.